

Open in app ↗



Search

Write



★ Get unlimited access to the best of Medium for less than \$1/week. [Become a member](#)



Agrupamiento de imágenes con mapas auto-organizados



Mayra Sarahí de Luna Castillo

9 min read · 4 days ago



La creciente abundancia de datos visuales en diversas disciplinas ha impulsado la necesidad de desarrollar técnicas avanzadas para el análisis y agrupamiento de imágenes. En este contexto, los mapas auto-organizados han surgido como una herramienta poderosa y eficiente para la organización y extracción de patrones en conjuntos de datos visuales complejos. Este método no solo facilita la visualización de similitudes entre imágenes, sino que también permite descubrir relaciones intrínsecas y patrones latentes en los conjuntos de datos visuales.

En este trabajo, exploraremos la aplicación de mapas auto-organizados para el agrupamiento de imágenes en tres diferentes bases de datos para observar sus resultados, beneficios y conclusiones. Las bases de datos usadas, ya se implementaron con otros algoritmos (SVM lineal, SVM radial y Perceptrón

Multicapa) en un blog anterior, si te interesa conocer lo que se realizó en ese trabajo, te dejo el link:


Clasificación de imágenes con métodos clásicos y redes neuronales

La clasificación de imágenes es una tarea dentro del campo de la visión por computadora que implica asignar una...

medium.com

Descripción de los datos utilizados para esta parte del proyecto.

Para realizar este proyecto manejamos tres bases de datos. La primera es la Fashion-MNIST con 70000 imágenes escaladas y normalizadas (60000 de entrenamiento y 10000 de prueba) de 10 clases de prendas de vestir (blusa, pantalón, suéter, vestido, abrigo, zapatos, playera, tenis, bolsa, botas) en escala de grises de tamaño 28x28. Las imágenes están perfectamente centradas y las distintas prendas tienen la misma figura.



Ejemplo de la base de datos Fashion-MNIST

La segunda es una base de 2000 fotografías satelitales de ambientes de México. Las fotografías son de alta calidad y muestran imágenes de Agua, Bosque, Ciudad, Cultivo, Desierto y Montaña.



Ejemplo de la base de datos Fotografías Satelitales

Por último, para la tercera base de datos, se utilizó una base de datos de 2,500 imágenes tomadas por nosotros, se tomaron 500 imágenes (con diferentes ángulos e iluminación) de cada una de estas imágenes son de un zapato, una gorra, un celular, un lápiz y un libro.



Ejemplo de la base de datos de fotografías propias

Descripción de la teoría de los modelos entrenados.


Los Mapas Auto-Organizados (SOM), también conocidos como redes de Kohonen, son una técnica de aprendizaje no supervisado utilizada en el campo de la inteligencia artificial y el procesamiento de datos. Fueron desarrollados por el científico finlandés Teuvo Kohonen en la década de 1980.

Los SOM son unas redes neuronales que se utilizan para organizar y visualizar información multidimensional de manera topológica, es decir, que las relaciones espaciales y las similitudes entre los datos en el espacio de

entrada se reflejarán en el espacio de salida. Entre sus principios claves se encuentran:

1. **Reducción de dimensionalidad:** Los SOM son eficaces para reducir la dimensionalidad de los datos de entrada.
2. **Adaptabilidad:** Los SOM son adaptables y pueden ajustarse a diferentes tipos de datos y distribuciones
3. **Mapeo topológico:** La organización de los nodos en el mapa refleja la topología del espacio de entrada.
4. **Competencia:** Los nodos en un SOM compiten entre sí por ser activados en respuesta a un estímulo. (Mapas Autoorganizados, s.f.)

La forma en que trabajan los SOM es a través de funciones de vecindad para agrupar los datos. Los nodos que se encuentran en la segunda capa compiten entre sí, comparándose con las regiones generadas en las que la red contiene nodos con pesos coincidentes con los vectores de entrenamiento. Con cada neurona que resulta “ganadora”, se actualizan los pesos de esa y sus neuronas vecinas, en proporción a la proximidad, según su función de vecindad. (¿Qué es Mapas-Autoorganizados?, s.f.)



Self Organizing Maps. Recuperado de <https://towardsdatascience.com/self-organizing-maps-1b7d2a84e065>

Si deseas profundizar en el funcionamiento del algoritmo estos videos pueden ser útiles

Video breve que explica el funcionamiento de SOM. Recuperado de <https://www.youtube.com/watch?v=H9H6s-x-0YE>

Explicación más detallada de SOM junto con código en Python. Recuperado de
https://www.youtube.com/watch?v=Oqtvb_Nx2tA


A las bases de datos de imágenes satelitales e imágenes propias se les tuvieron que extraer dos características importantes, sus histogramas de color RGB (rojo, azul y verde) y las matrices de concurrencia que describe las relaciones entre los píxeles de una imagen.

Resultados obtenidos con los diferentes modelos y conjuntos de datos.

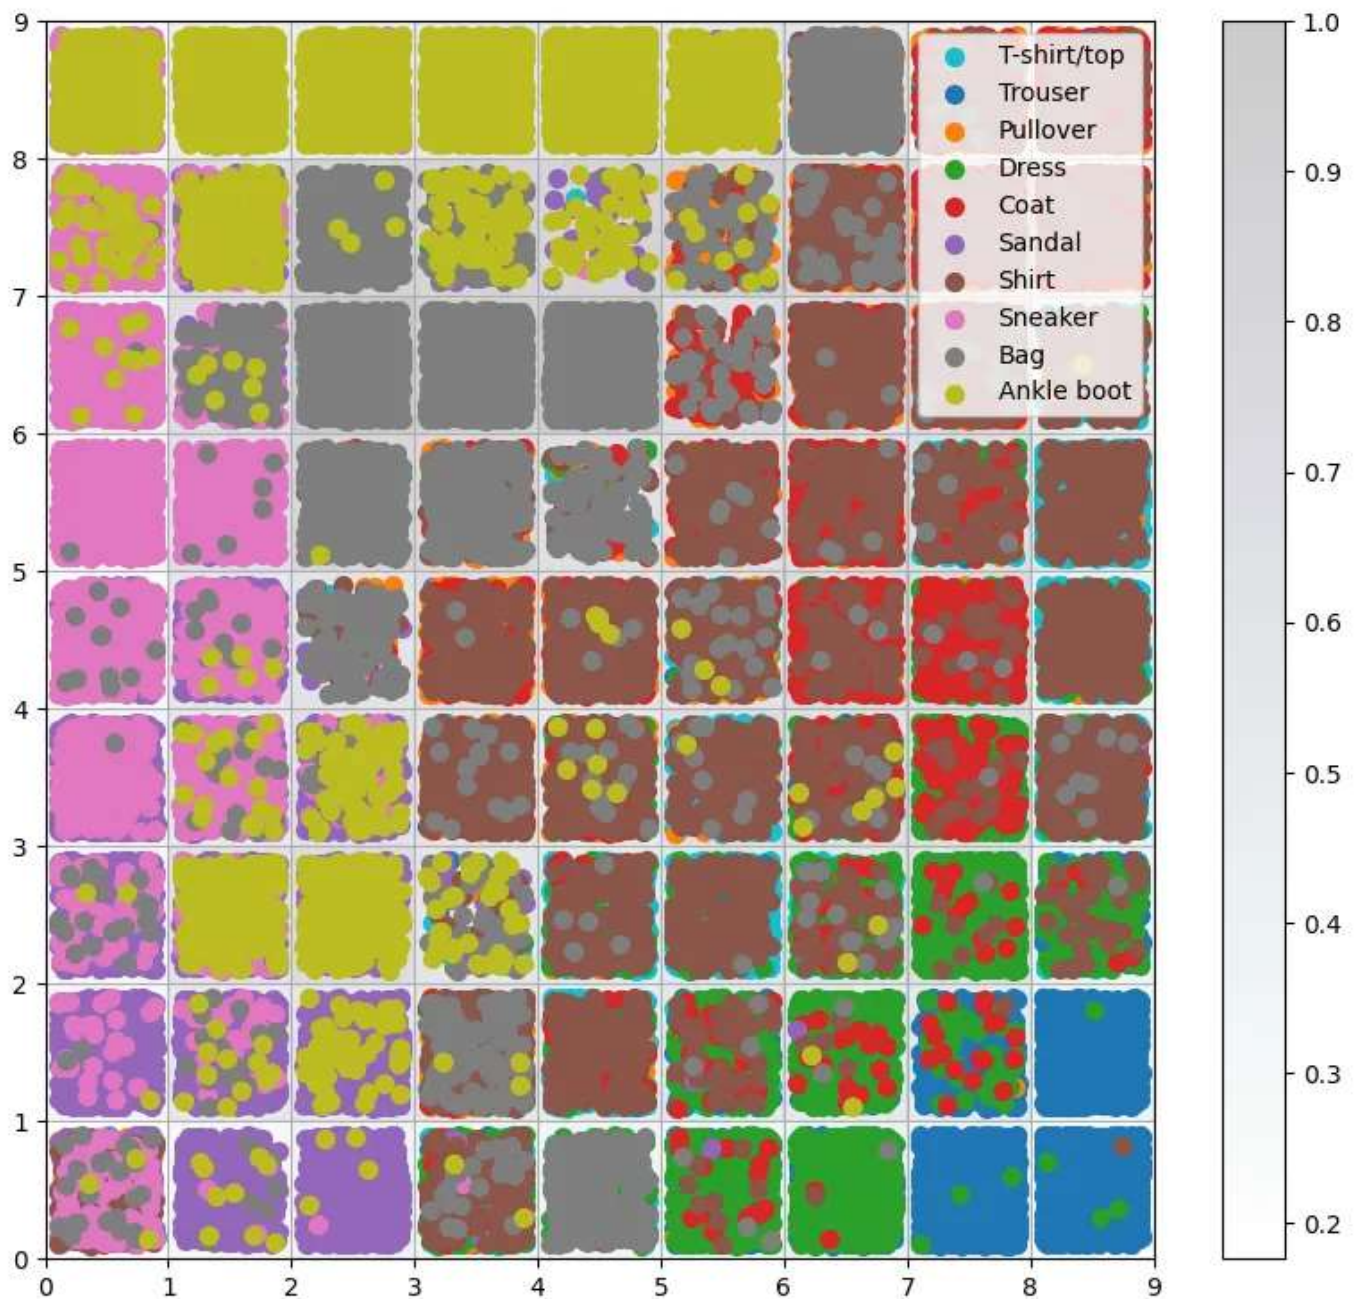
Para realizar los mapas auto-organizados se utilizó la librería `minisom` (mini Self-Organizing Map) que es una implementación minimalista de los Mapas Auto-organizados (SOM) en Python. (Minisom,s.f.)

El código que se uso para implementar SOM en Python se baso en la guía de [uso básico de minisom](#), con ese script del repositorio de GitHub podrías realizar estas mismas gráficas que se muestran a continuación.

- **Fashion-MNIST** : A continuación se muestran las 4 representaciones de SOM para la base de datos Fashion-MNIST




Gráfica SOM 1 de Fashion-MNIST



Gráfica SOM 2 de Fashion-MNIST

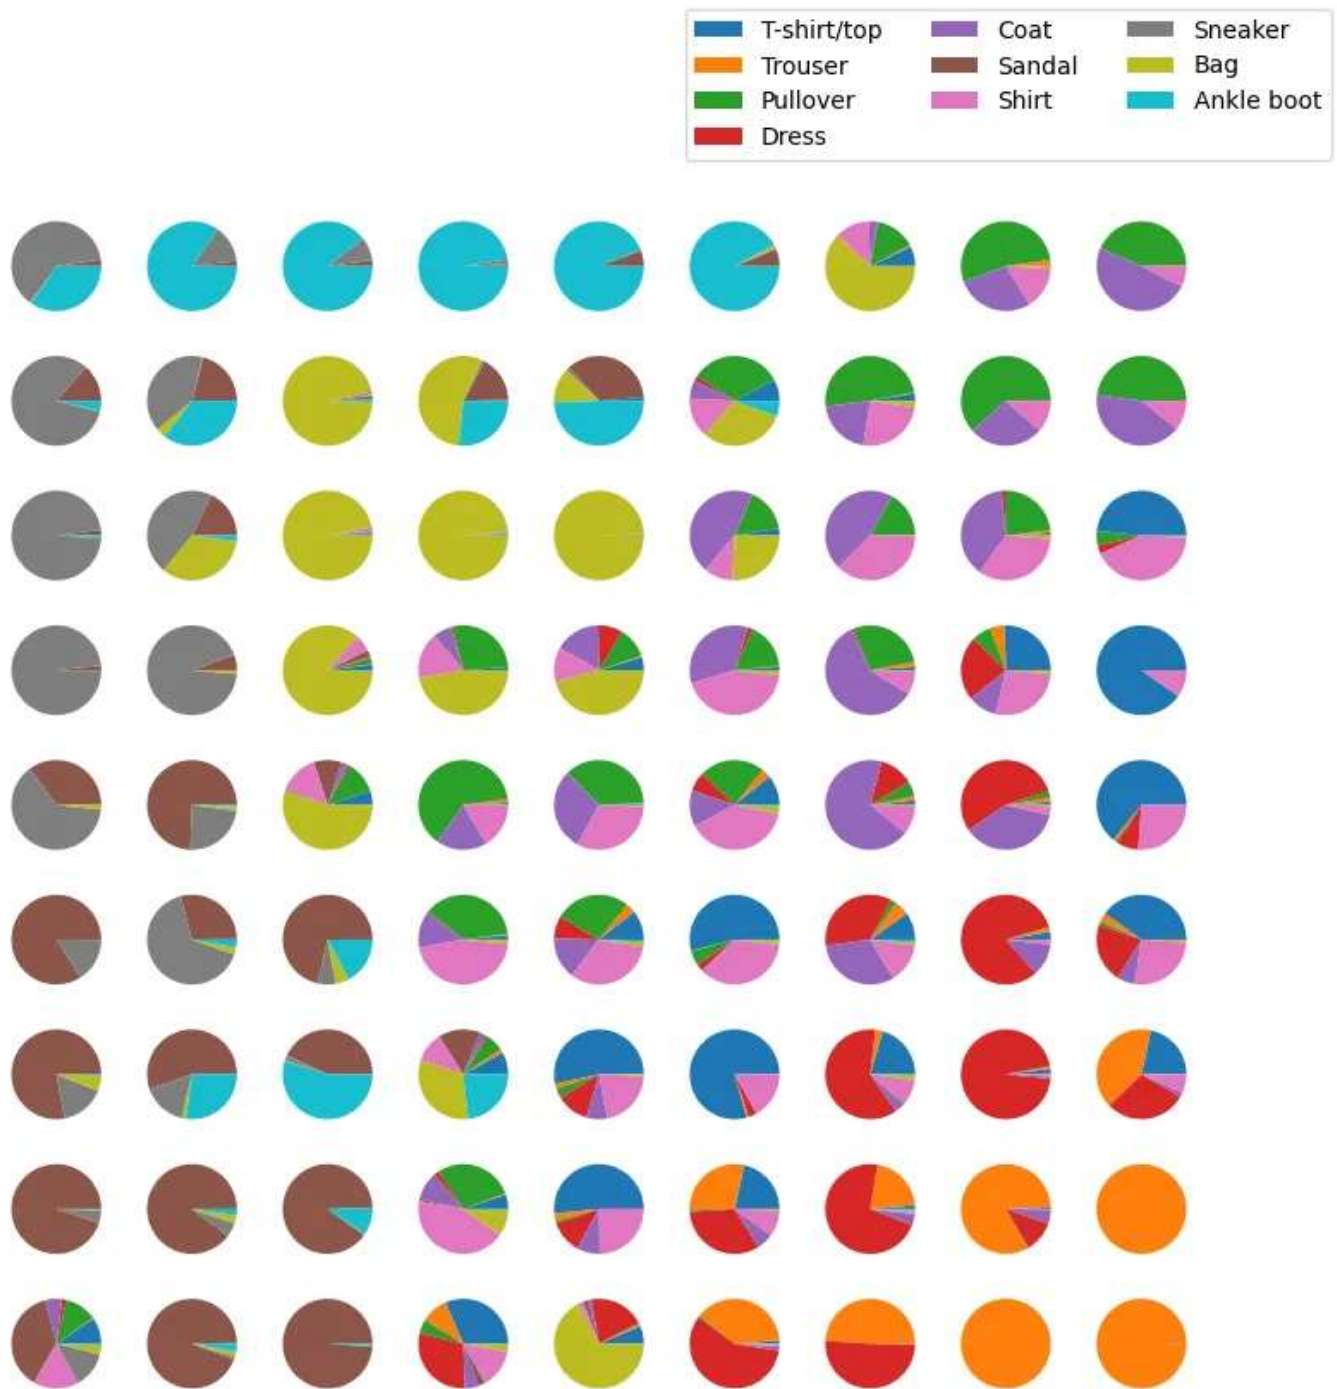
Con las dos representaciones anteriores podemos observar como se distribuyen las muestras en el mapa, cada punto representan las coordenadas de la neurona ganadora. “Ankle Boot” se encuentran agrupadas en la parte izquierda-superior, cerca de “Sneakers” que se encuentran abajo de estas y de lado derecho se encuentran “Bags”, también se puede observar

que en el centro del mapa predominan las neuronas de “Shirt”, en la parte inferior derecha se agrupan “Trousers” junto con las neuronas que agrupan “Dress”. En este caso, “Sandal”, “T-shirt” y “Coat” no tienen una gran cantidad de neuronas ganadoras.



Gráfica SOM 3 de Fashion-MNIST


En esta representación gráfica, es posible identificar las neuronas del mapa que se activan con mayor frecuencia. Aquellas áreas coloreadas de manera más intensa indican una activación más frecuente, siendo las clases predominantes en este caso “Trousers”, “Dress” y “Shirt”.



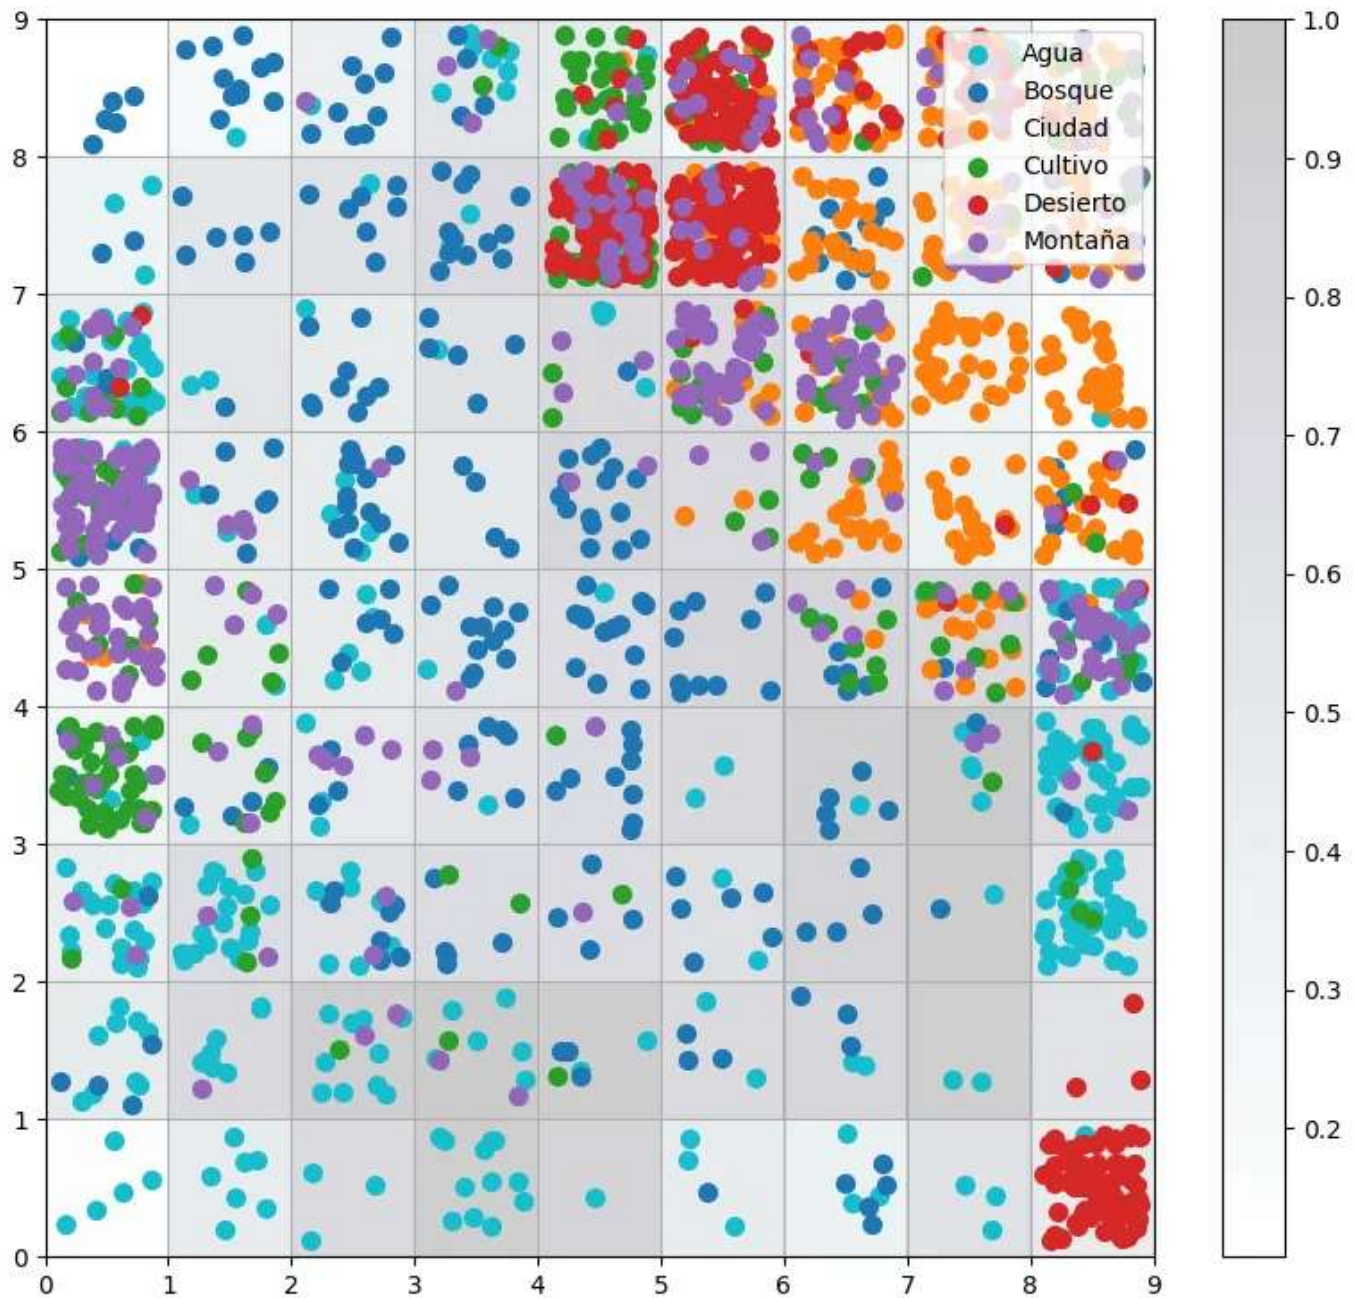
Gráfica SOM 4 de Fashion-MNIST

En este último gráfico se puede visualizar la proporción de muestras por clase que caen en una neurona específica, así podemos observar que clases contiene cada neurona y si existen neuronas que solo se activen con un solo producto (en este caso únicamente “Trouser” tiene 3 neuronas completas).

- **Fotografías satelitales:** A continuación se muestran las mismas 4 representaciones gráficas ahora para la base de datos de fotografías satelitales.




Gráfica SOM 1 de Fotografías satelitales



Gráfica SOM 2 de Fotografías satelitales

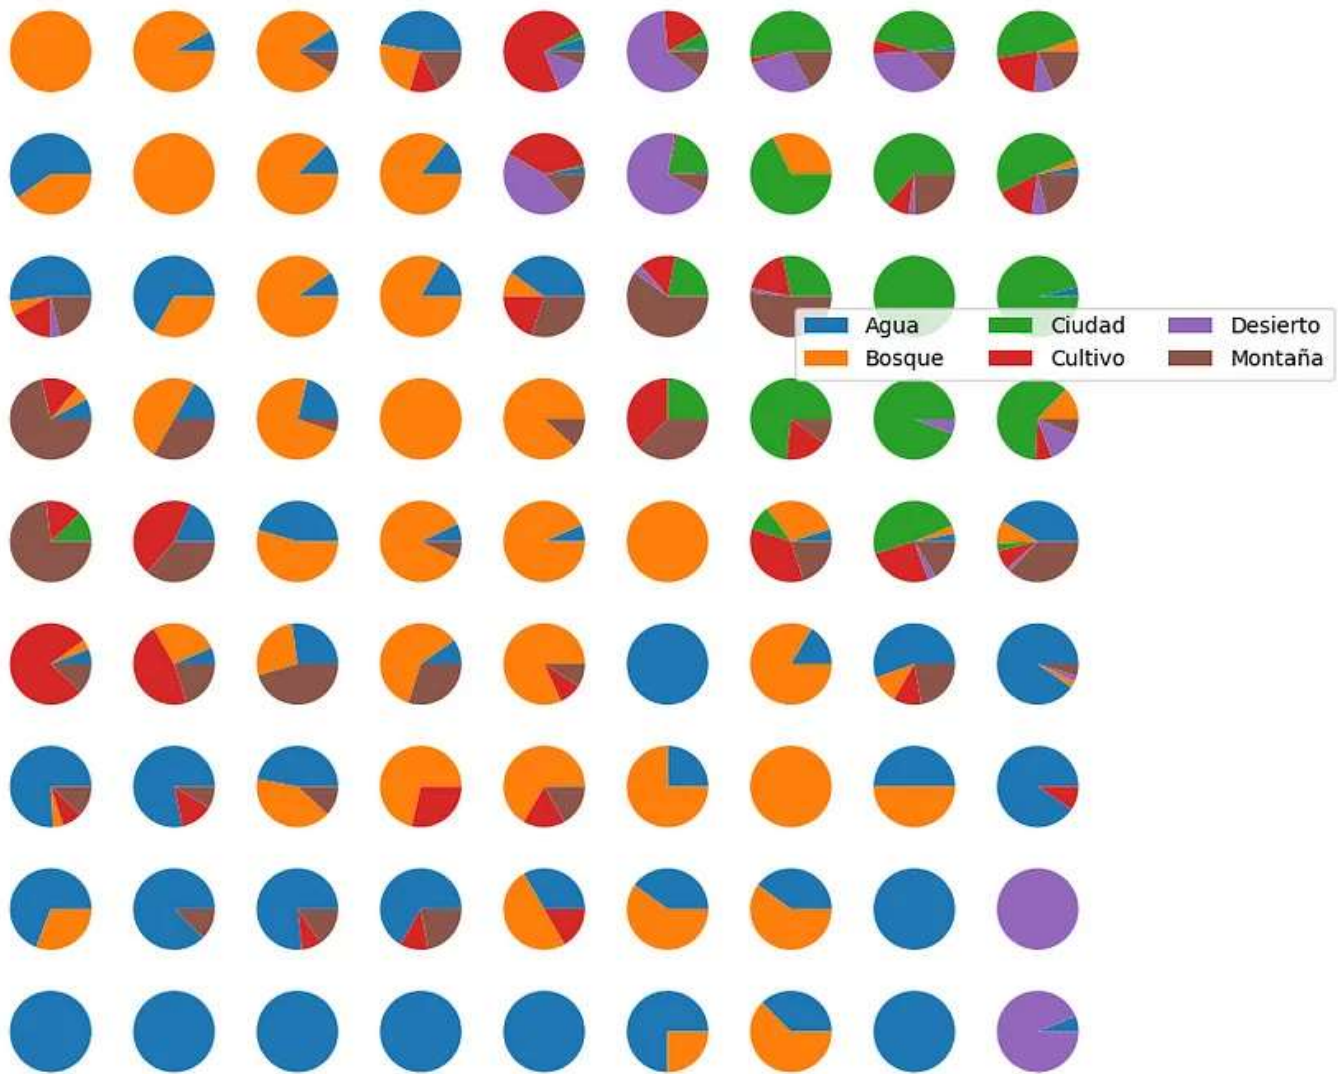
A diferencia del modelo anterior, en este caso se observa que las muestras de neuronas ganadoras están un poco más dispersas y menos definidas, a excepción de las fotografías de Desierto, Agua (ubicadas en la parte inferior), Ciudad y Bosque (ubicadas en el centro) donde se puede ver por lo menos 4 cuadrículas únicamente con neuronas de Agua, 1 cuadrícula con neuronas de Desierto, 1 cuadrícula de Ciudad y 3 de Bosque. Todas las demás clases pueden llegar a confundirse en cierto punto como es el caso de Cultivo y

Montaña, en donde se pueden ver que en general el color morado y verde tienden a mezclarse.



Gráfica SOM 3 de Fotografías satelitales


En este caso las neuronas que más se activan se encuentran en la parte superior derecha, que corresponderían mayormente a las clases de Desierto y Ciudad.



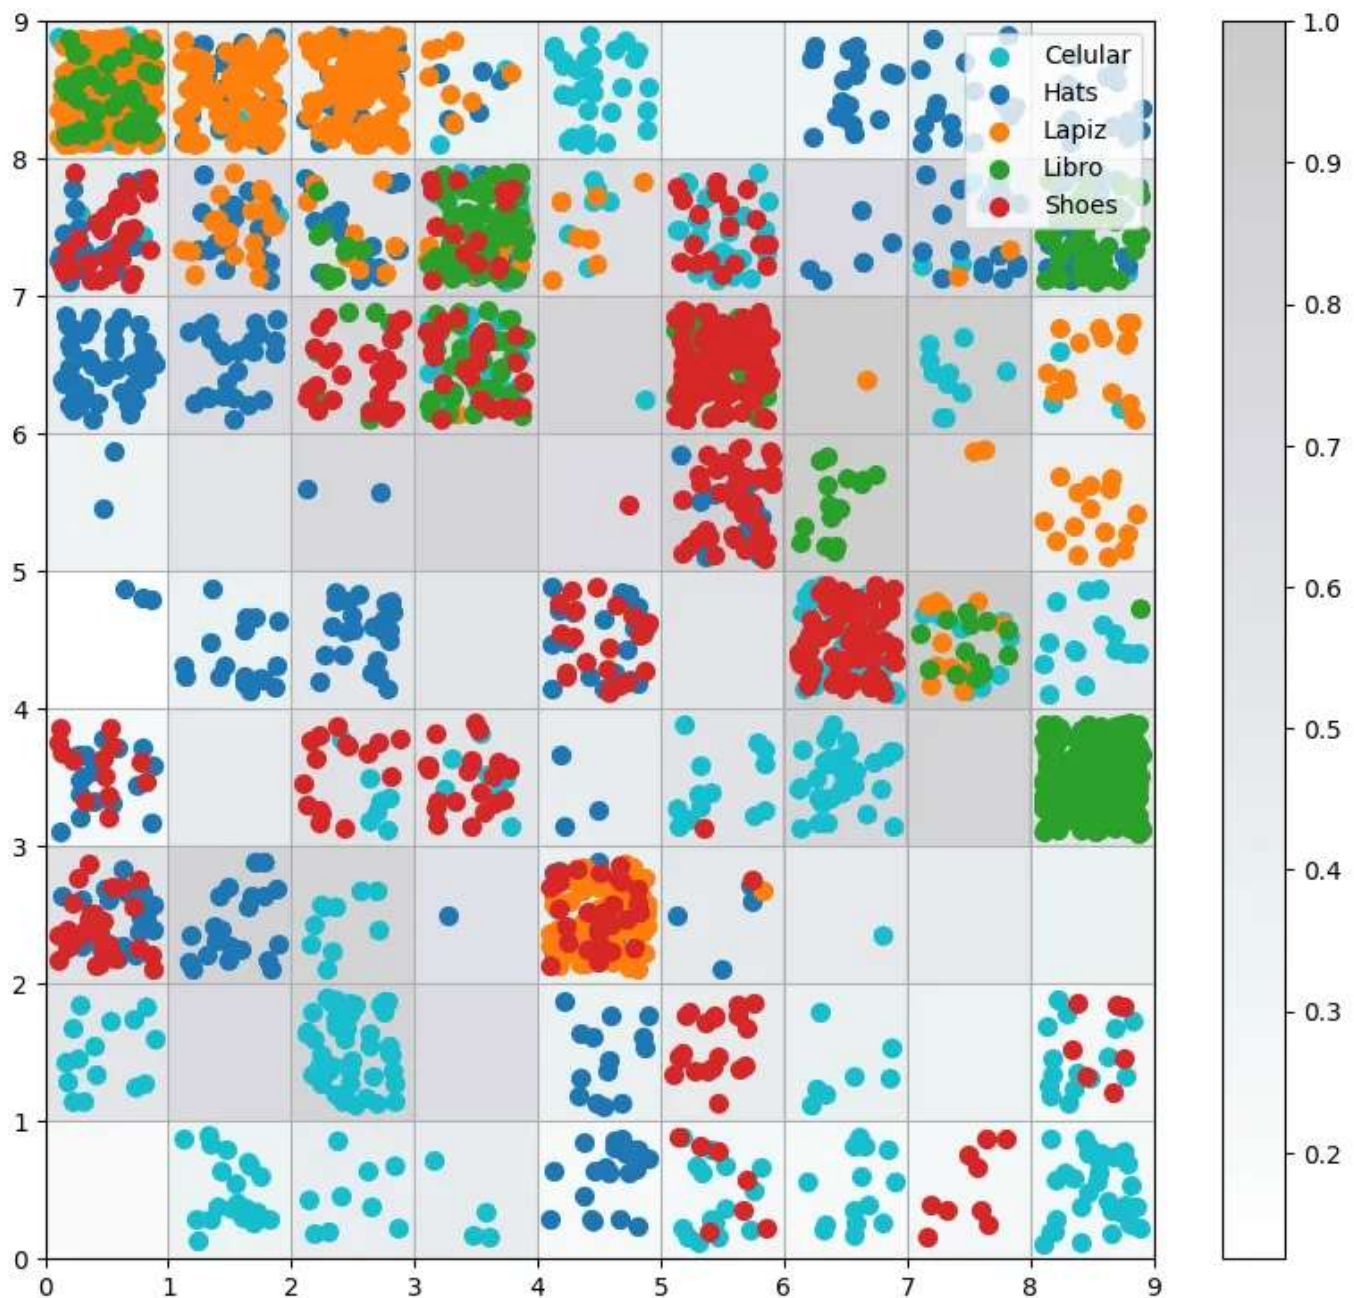
Gráfica SOM 4 de Fotografías satelitales

Finalmente, en esta gráfica podemos observar más a detalle cuántas neuronas completas tiene cada clase, y cuántas neuronas compartidas existen.

- **Fotografías de Objetos Propios:** A continuación se muestran las mismas 4 representaciones gráficas ahora para la base de datos de fotografías de objetos propios.




Gráfica SOM 1de Fotografías de Objetos



Gráfica SOM 2 de Fotografías de Objetos


Para esta base de datos, se observa que existen más neuronas de una sola clase que en el pasado, esto sucede debido a que las imágenes son menos complejas que las satelitales y se encuentran centradas, por lo que podemos esperar un buen resultado, además, el agrupamiento más notorio es en la clase “Celular” que se encuentra en la parte inferior izquierda y es la que cuenta con un mayor número de neuronas completas. El mapa en general se

ve bien clasificado a excepción de la clase “Shoes” que se encuentra por toda la cuadrícula.



Gráfica SOM 3 de Fotografías de Objetos

En este gráfico se observa que las neuronas que se activan con mayor frecuencia son aquellas relacionadas con la clase “Libros”, “Lápiz” y “Hats”.



Gráfica SOM 4 de Fotografías de Objetos

Finalmente, de manera más gráfica podemos ver que efectivamente para esta base de datos existe un mayor agrupamiento de neuronas de una sola clase.

Discusión sobre la eficacia de los modelos para agrupar los datos utilizados.

Fashion-MNIST

En esta base de datos, la mayoría de las neuronas almacenan información específica de una sola categoría, lo que resulta en una agrupación eficiente. Este fenómeno podría atribuirse al hecho de que las imágenes de Fashion-MNIST están perfectamente centradas, son fácilmente distinguibles, tienen un tamaño de píxel reducido y se presentan en una cantidad considerable (7,000). Además, las clases que son similares en la realidad, como los tenis y las botas, están ubicadas cercanas entre sí, mientras que se encuentran alejadas de objetos que son muy diferentes a ellas.

Imágenes satelitales

En este escenario, los resultados obtenidos mediante el SOM fueron favorables, ya que es posible identificar varias neuronas asociadas a una única categoría, lo que indica una buena agrupación. Sin embargo, las neuronas que combinan diferentes clases parecen más evidentes y son más numerosas, posiblemente debido a la limitada cantidad de imágenes en la base de datos (solo 2000) y a la mayor complejidad de las fotografías, que se basan también en la textura de las mismas. A pesar de esto, es válido destacar que en la gran mayoría de estas neuronas se puede observar una categoría ganadora.

Objetos cotidianos

En términos generales, la base de datos de objetos se caracteriza por su facilidad para ser clasificada, lo que genera expectativas positivas en cuanto a los resultados del SOM, incluso con solo 2,500 imágenes. Al examinar los gráficos de pastel, se evidencia la presencia predominante de neuronas

asociadas a una sola clase, y en aquellas que comparten categorías, se identifica claramente un ganador.

Aunque el agrupamiento con estas imágenes es preciso, se nota que hay una clase, “Zapatos”, dispersa en el mapa. Esta dispersión podría atribuirse a la diversidad de los zapatos utilizados, lo que posiblemente cause cierta confusión al algoritmo durante el proceso de clasificación.

Conclusiones

Después la recopilación de información y análisis de las representaciones gráficas generadas por el Self-Organizing Map (SOM), se llega a la conclusión de que este método de agrupación es una herramienta viable tanto para imágenes de naturaleza sencilla como para aquellas de mayor complejidad. Esta viabilidad se aprecia siempre y cuando exista una notoria diferenciación entre las distintas clases presentes en las imágenes.

Si bien el SOM exhibió un desempeño adecuado en las tres bases de datos evaluadas, su eficiencia se encuentra sujeta a diversas variables. Entre estas variables, la cantidad de imágenes, la complejidad de las mismas, la calidad de la información proporcionada y las diferencias entre las clases.

Finalmente, los resultados obtenidos respaldan la premisa de que los Mapas Auto-Organizativos (SOM) constituyen una opción robusta y efectiva para la clasificación de imágenes. La capacidad del SOM para discernir patrones y organizar información lo posiciona como una valiosa alternativa en el ámbito de la clasificación de imágenes.

Referencias

¿Qué es Mapas-Autoorganizados?. (s.f.). *GAMCO*. Recuperado de <https://gamco.es/glosario/mapa-auto-organizado-som-de-kohonen/>

Minisom. *GitHub*. Recuperado de <https://github.com/JustGlowing/minisom/blob/master/examples/BasicUsage.ipynb>

Mapas Autoorganizados.(s.f.). *Universidad de Salamanca*. Recuperado de <http://avellano.usal.es/~lalonso/RNA/introSOM.htm>

Self Organising Map: Introduction. Recuperado de https://www.youtube.com/watch?v=0qtvb_Nx2tA

How SOM Algorithm works. Recuperado de <https://www.youtube.com/watch?v=H9H6s-x-0YE>

Machine Learning



Written by Mayra Sarahí de Luna Castillo

Edit profile